“AI+X微专业”基础类课程

华五教学协同中心
Consortium for the Advancement of Teaching and Learning at E5

《模式识别与机器学习》
第六讲：卷积神经网络

邱锡鹏
复旦大学 计算机学院
xpqiu@fudan.edu.cn

2021年5月20日

路线图

- 机器学习
  - 机器学习概述
  - 监督学习
    - 回归
      - 线性回归
        - 曲线拟合
    - 分类
      - 基于实例的分类器
        - kNN
      - 基于规则的分类器
        - 决策树
      - 线性分类器
        - 感知器
        - Logistic回归
        - SVM
      - 非线性分类器
        - 神经网络
          - 前馈神经网络 

          - 卷积神经网络
          - 循环神经网络
          - 注意力机制
      - 集成分类器
  - 无监督学习
    - 聚类
      - kMeans
    - 降维
      - PCA
      - 自编码器
    - 密度估计
  - 强化学习

内容

- 卷积
  - 一维卷积
  - 二维卷积
- 卷积神经网络
- 其它卷积种类
  - 空洞卷积
  - 转置卷积/微步卷积
- 典型的卷积网络
  - AlexNet、LeNet5、ResNet
- 应用

本讲内容主要来自

- 《神经网络与深度学习》 邱锡鹏
  - 第5章 卷积神经网络

全连接前馈神经网络

- 权重矩阵的参数非常多

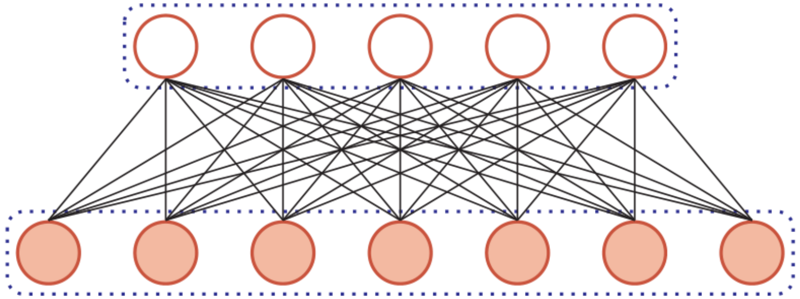

- 局部不变性特征
  - 自然图像中的物体都具有局部不变性特征
    - 尺度缩放、平移、旋转等操作不影响其语义信息。
  - 全连接前馈网络很难提取这些局部不变特征

卷积神经网络

- 卷积神经网络（Convolutional Neural Networks，CNN）
  - 一种前馈神经网络
  - 受生物学上感受野（Receptive Field）的机制而提出的
    - 在视觉神经系统中，一个神经元的感受野是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元。

- 卷积神经网络有三个结构上的特性：
  - 局部连接
  - 权重共享
  - 空间或时间上的次采样

卷积

- 卷积经常用在信号处理中，用于计算信号的延迟累积。
- 假设一个信号发生器每个时刻t产生一个信号x_t，其信息的衰减率为w_k，即在k−1个时间步长后，信息为原来的w_k倍
  - 假设$w_1 = 1, w_2 = 1/2, w_3 = 1/4$
- 时刻t收到的信号y_t为当前时刻产生的信息和以前时刻延迟信息的叠加

$$
\begin{aligned}
y_t &= 1 \times x_t + 1/2 \times x_{t-1} + 1/4 \times x_{t-2} \\
&= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} \\
&= \sum_{k=1}^{3} w_k \cdot x_{t-k+1}.
\end{aligned}
$$

滤波器（filter）或卷积核（convolution kernel）

卷积

- 给定一个输入信号序列x和滤波器w,卷积的输出为：

$$y_t = \sum_{k=1}^{K} w_k x_{t-k+1}$$

Filter: [-1,0,1]

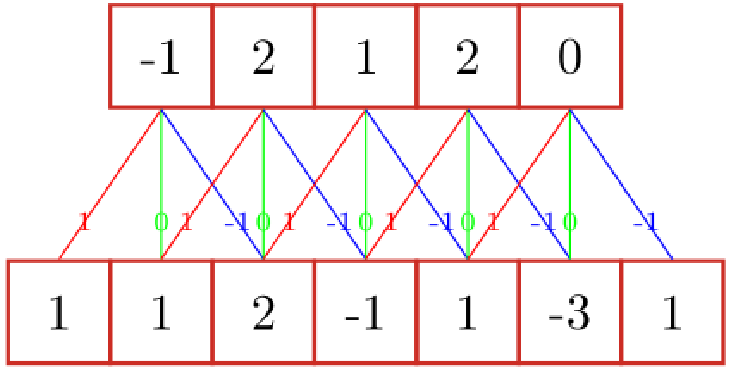

卷积的作用

- 近似微分
  - 当令滤波器$\boldsymbol{w} = [1/2, 0, -1/2]$时，可以近似信号序列的一阶微分

$$x'(t) = \frac{x(t+1) - x(t-1)}{2}$$

  - 当令滤波器$\boldsymbol{w} = [1, -2, 1]$时，可以近似信号序列的二阶微分

$$x''(t) = x(t+1) + x(t-1) - 2x(t)$$

卷积的作用

- 低通滤波/高通滤波
  - 滤波器$\boldsymbol{w}=[1/3, 1/3, 1/3]$ 可以检测信号序列中的低频信息
  - 滤波器$\boldsymbol{w}=[1, -2, 1]$ 可以检测信号序列中的高频信息

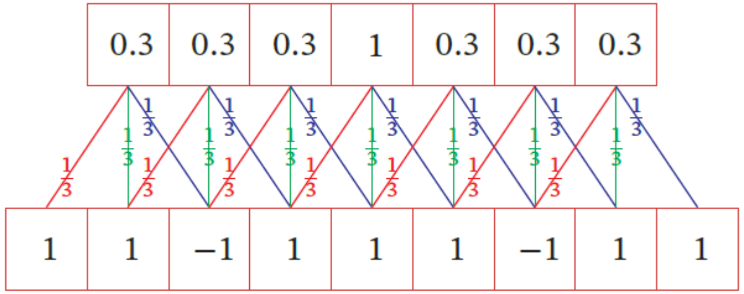

(a) 滤波器 [1/3, 1/3, 1/3]

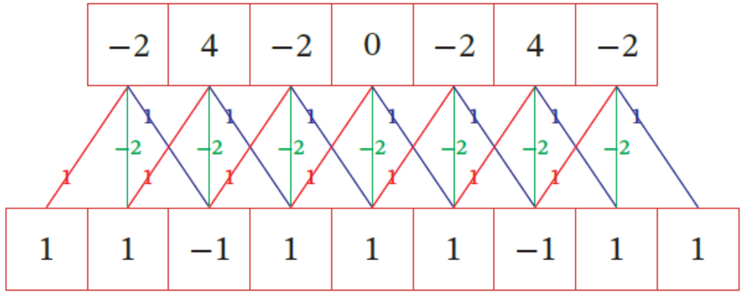

(b) 滤波器 [1, −2, 1]

卷积扩展

- 引入滤波器的滑动步长S和零填充P

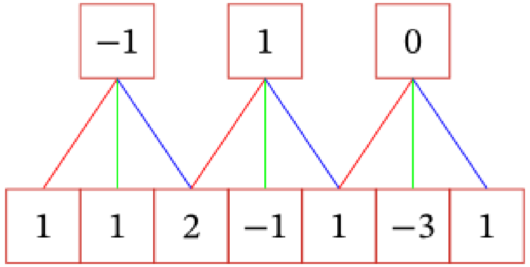

(a) 步长 $S = 2$

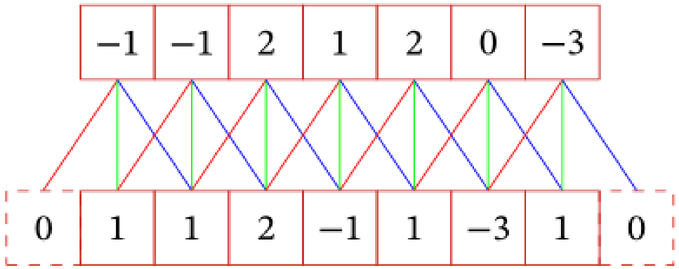

(b) 零填充 $P = 1$

卷积类型

- 卷积的结果按输出长度不同可以分为三类:
  - 窄卷积：步长 $S=1$，两端不补零 $P=0$，输出长度为 $M-K+1$
  - 宽卷积：步长 $S=1$，两端补零 $P=K-1$，输出长度 $M+K-1$
  - 等宽卷积：步长$S=1$，两端补零 $P=(K-1)/2$，输出长度 M

- 在早期的文献中，卷积一般默认为窄卷积。
- 而目前的文献中，卷积一般默认为等宽卷积。

两维卷积

- 在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积。

一个输入信息 $\boldsymbol{X}$ 和滤波器 $\boldsymbol{W}$ 的二维卷积定义为

$$\boldsymbol{Y} = \boldsymbol{W} * \boldsymbol{X},$$

$$y_{ij} = \sum_{u=1}^{U} \sum_{v=1}^{V} w_{uv} x_{i-u+1,j-v+1}.$$

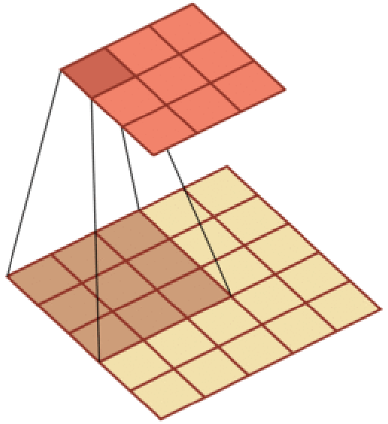

$$\begin{array}{|c|c|c|c|c|}\hline 1 & 1 & 1_{\times -1} & 1_{\times 0} & 1_{\times 0} \\ \hline -1 & 0 & -3_{\times 0} & 0_{\times 0} & 1_{\times 0} \\ \hline 2 & 1 & 1_{\times 0} & -1_{\times 0} & 0_{\times 1} \\ \hline 0 & -1 & 1 & 2 & 1 \\ \hline 1 & 2 & 1 & 1 & 1 \\ \hline \end{array} * \begin{array}{|c|c|c|}\hline 1 & 0 & 0 \\ \hline 0 & 0 & 0 \\ \hline 0 & 0 & -1 \\ \hline \end{array} = \begin{array}{|c|c|c|}\hline 0 & -2 & -1 \\ \hline 2 & 2 & 4 \\ \hline -1 & 0 & 0 \\ \hline \end{array}$$

二维卷积

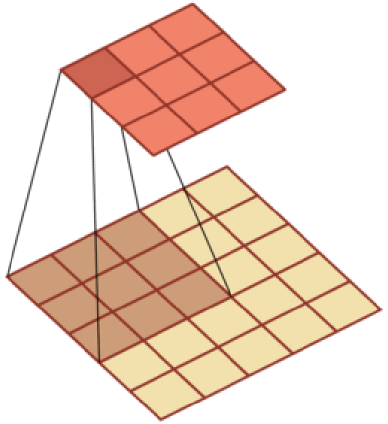

步长1，零填充0

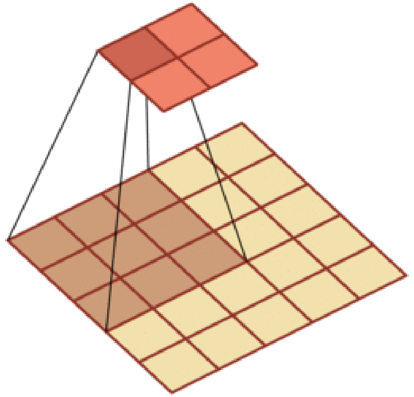

步长2，零填充0

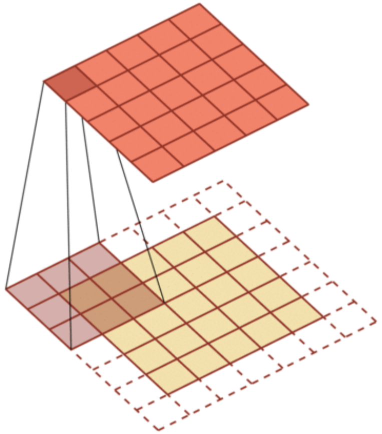

步长1，零填充1

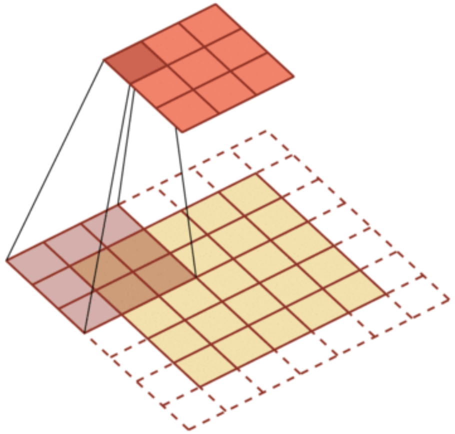

步长2，零填充1

卷积作为特征提取器

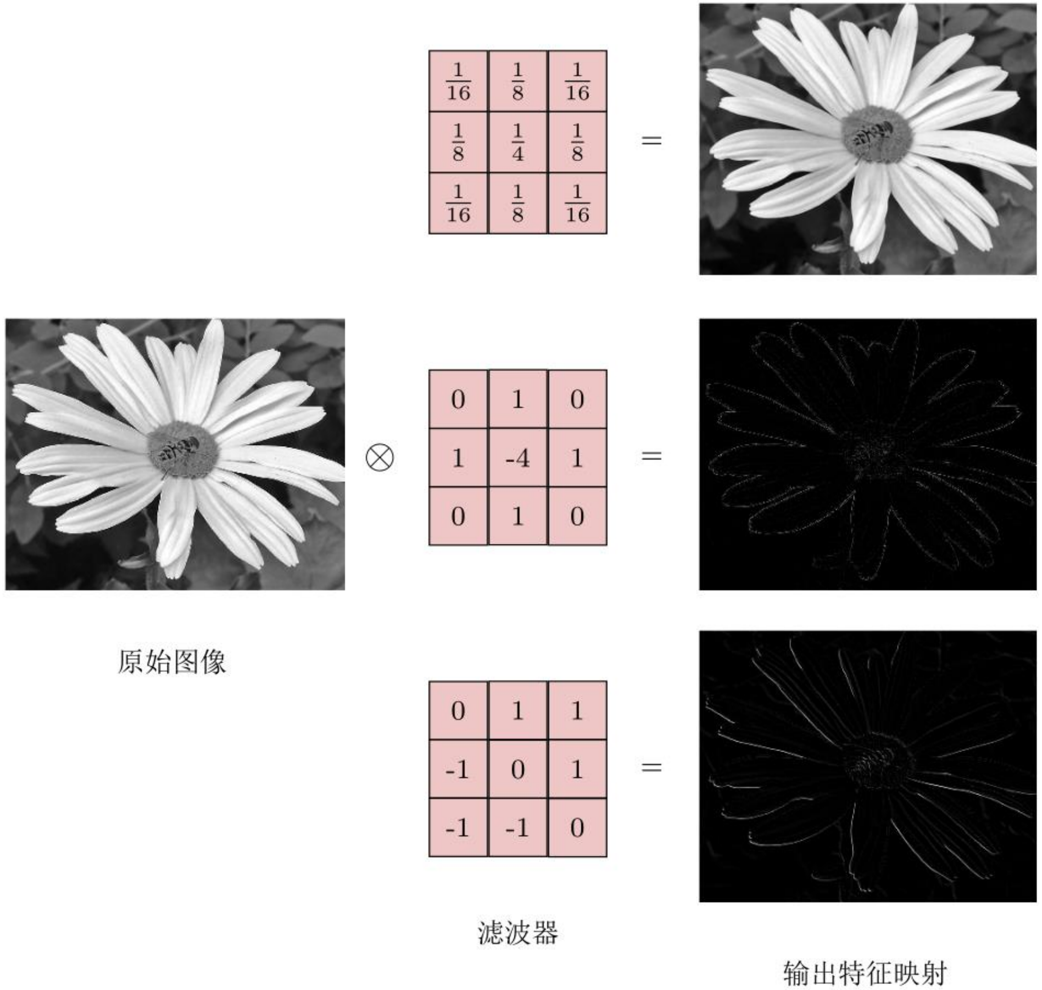

卷积神经网络

卷积神经网络

- 用卷积层代替全连接层

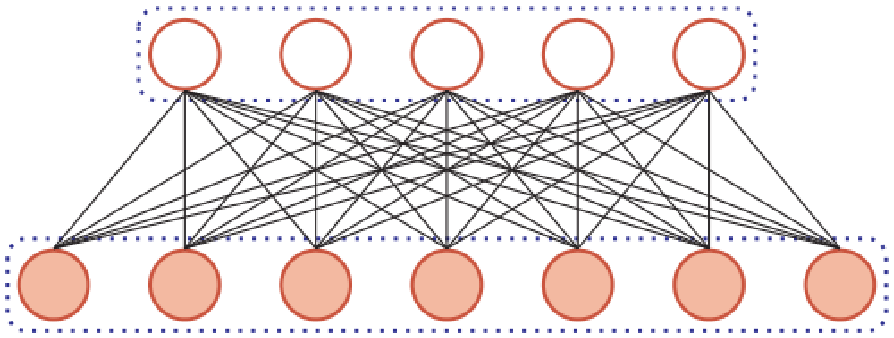

(a) 全连接层

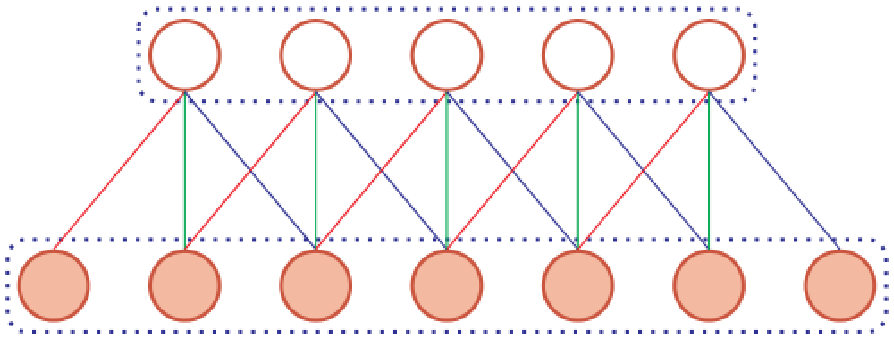

(b) 卷积层

互相关

- 计算卷积需要进行卷积核翻转。
- 卷积操作的目标：提取特征。

翻转是不必要的！

- 互相关

$$y_{ij} = \sum_{u=1}^{m} \sum_{v=1}^{n} w_{uv} \cdot x_{i+u-1,j+v-1}$$

除非特别声明，卷积一般指“互相关”。

多个卷积核

- 卷积核看成一个特征提取器
  - 如何增强卷积层的能力?
    - 引入多个卷积核
- 以两维为例:
  - 特征映射（Feature Map）：图像经过卷积后得到的特征。
  - 卷积层
    - 输入：D个特征映射 $M \times N \times D$
    - 输出：P个特征映射 $M' \times N' \times P$

卷积层的映射关系

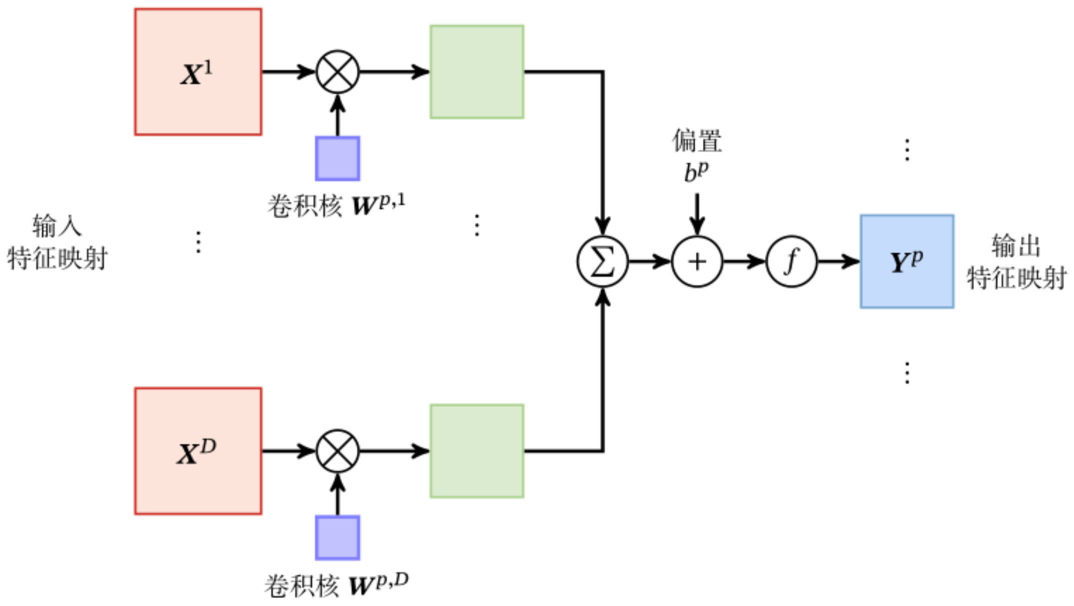

$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^{D} W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$

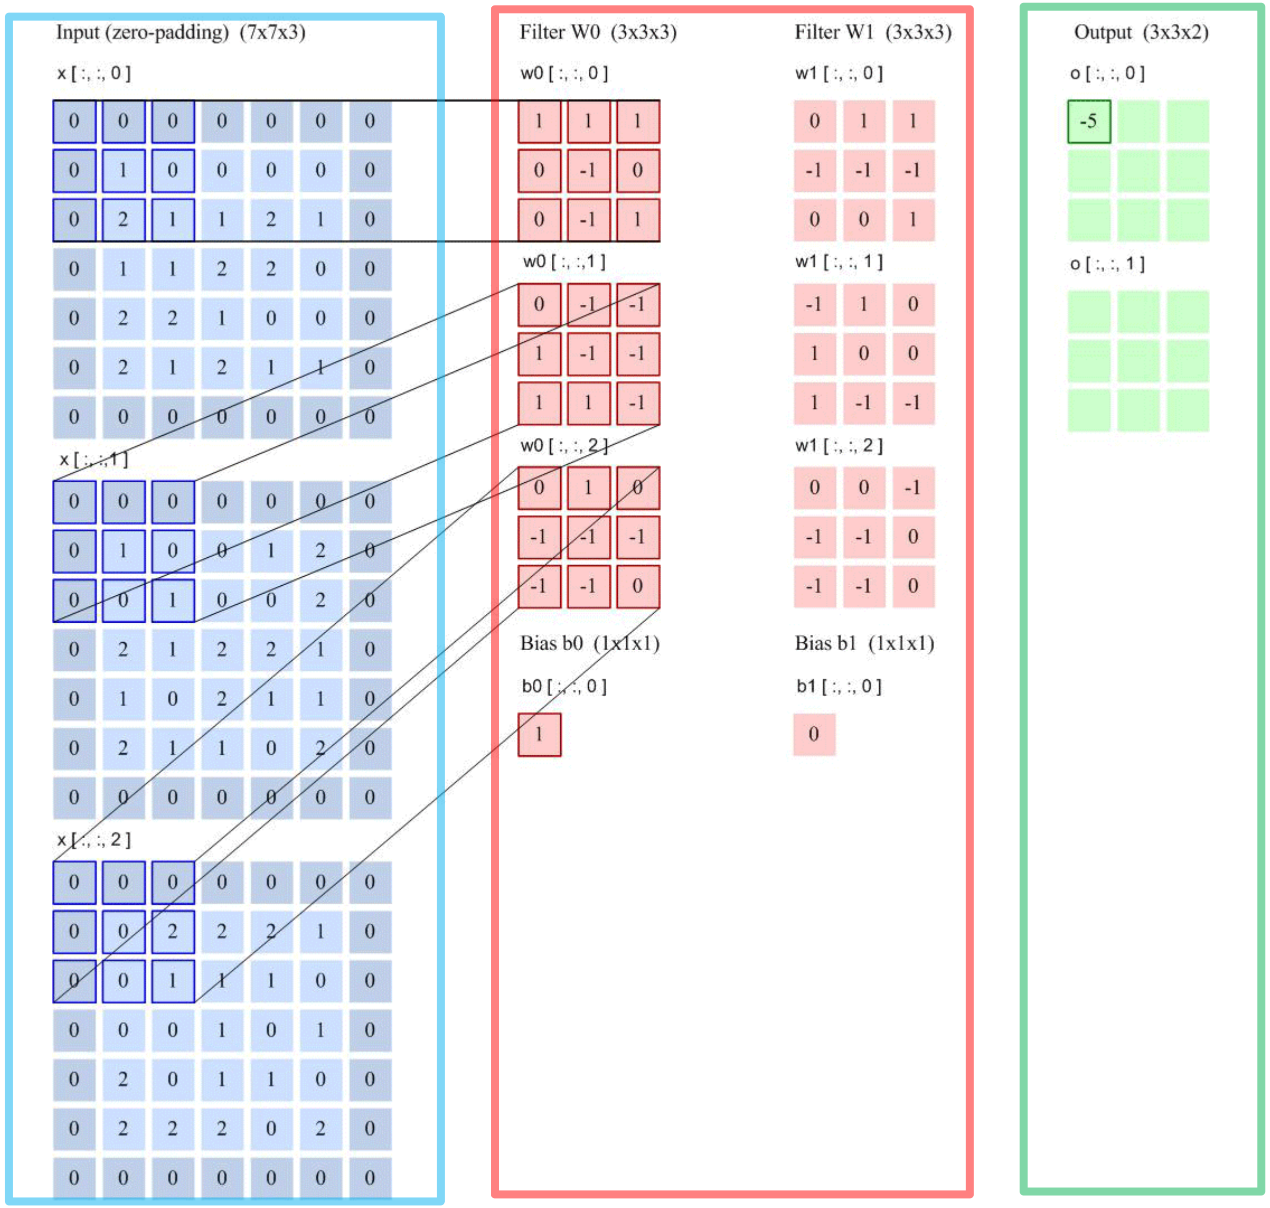

步长2
filter 3*3
filter个数6
零填充 1

卷积层

- 典型的卷积层为3维结构

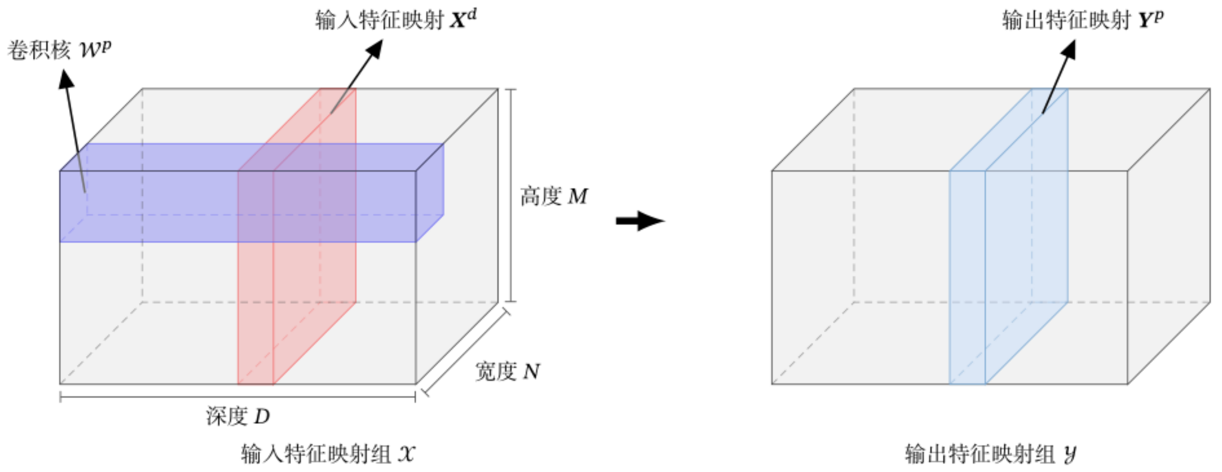

$$
\boldsymbol{Z}^p = \boldsymbol{W}^p \otimes \boldsymbol{X} + b^p = \sum_{d=1}^{D} \boldsymbol{W}^{p,d} \otimes \boldsymbol{X}^d + b^p,
$$

$$
\boldsymbol{Y}^p = f(\boldsymbol{Z}^p).
$$

汇聚层（Pooling Layers）

- 卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。

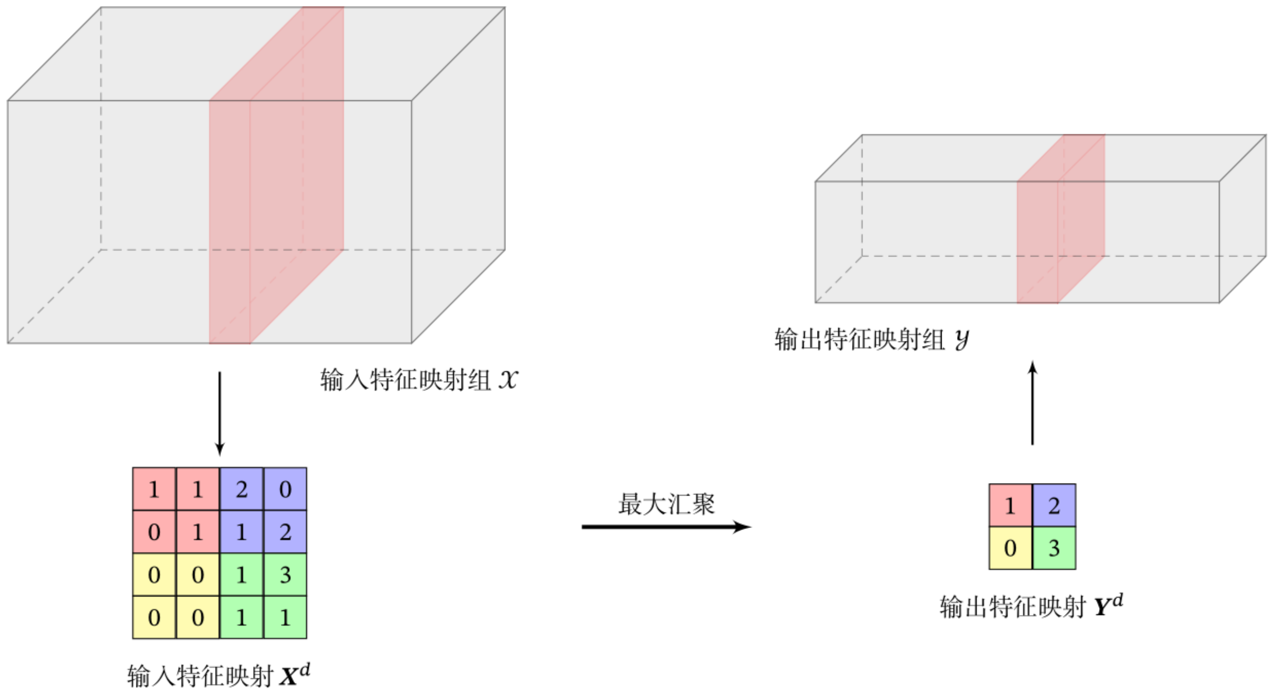

卷积网络结构

- 卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。

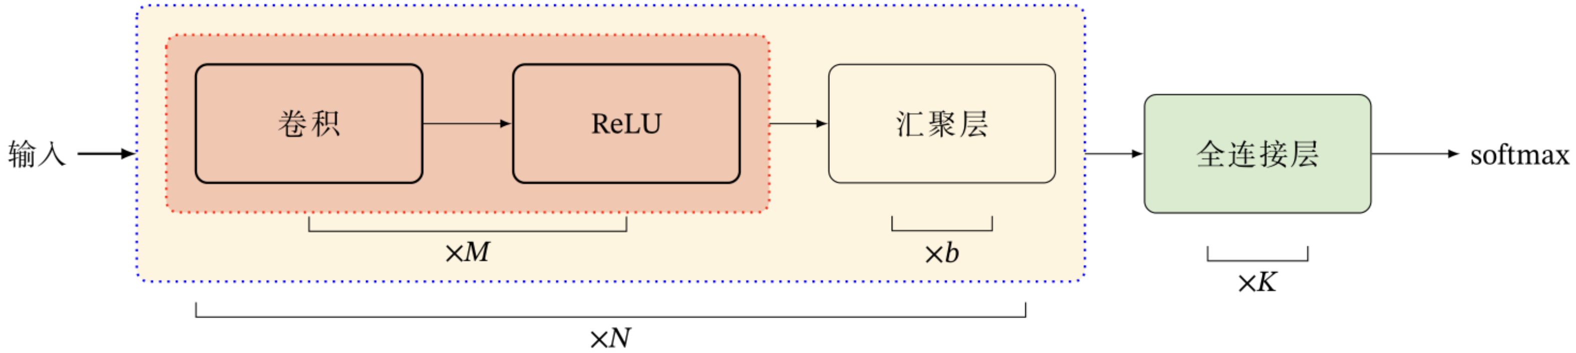

  - 一个卷积块为连续M 个卷积层和b个汇聚层（M通常设置为2～5，b为0或1）。一个卷积网络中可以堆叠N 个连续的卷积块，然后在接着K 个全连接层（N 的取值区间比较大，比如1～100或者更大；K一般为0～2)

- 典型结构
  - 趋向于小卷积、大深度
  - 趋向于全卷积

表示学习

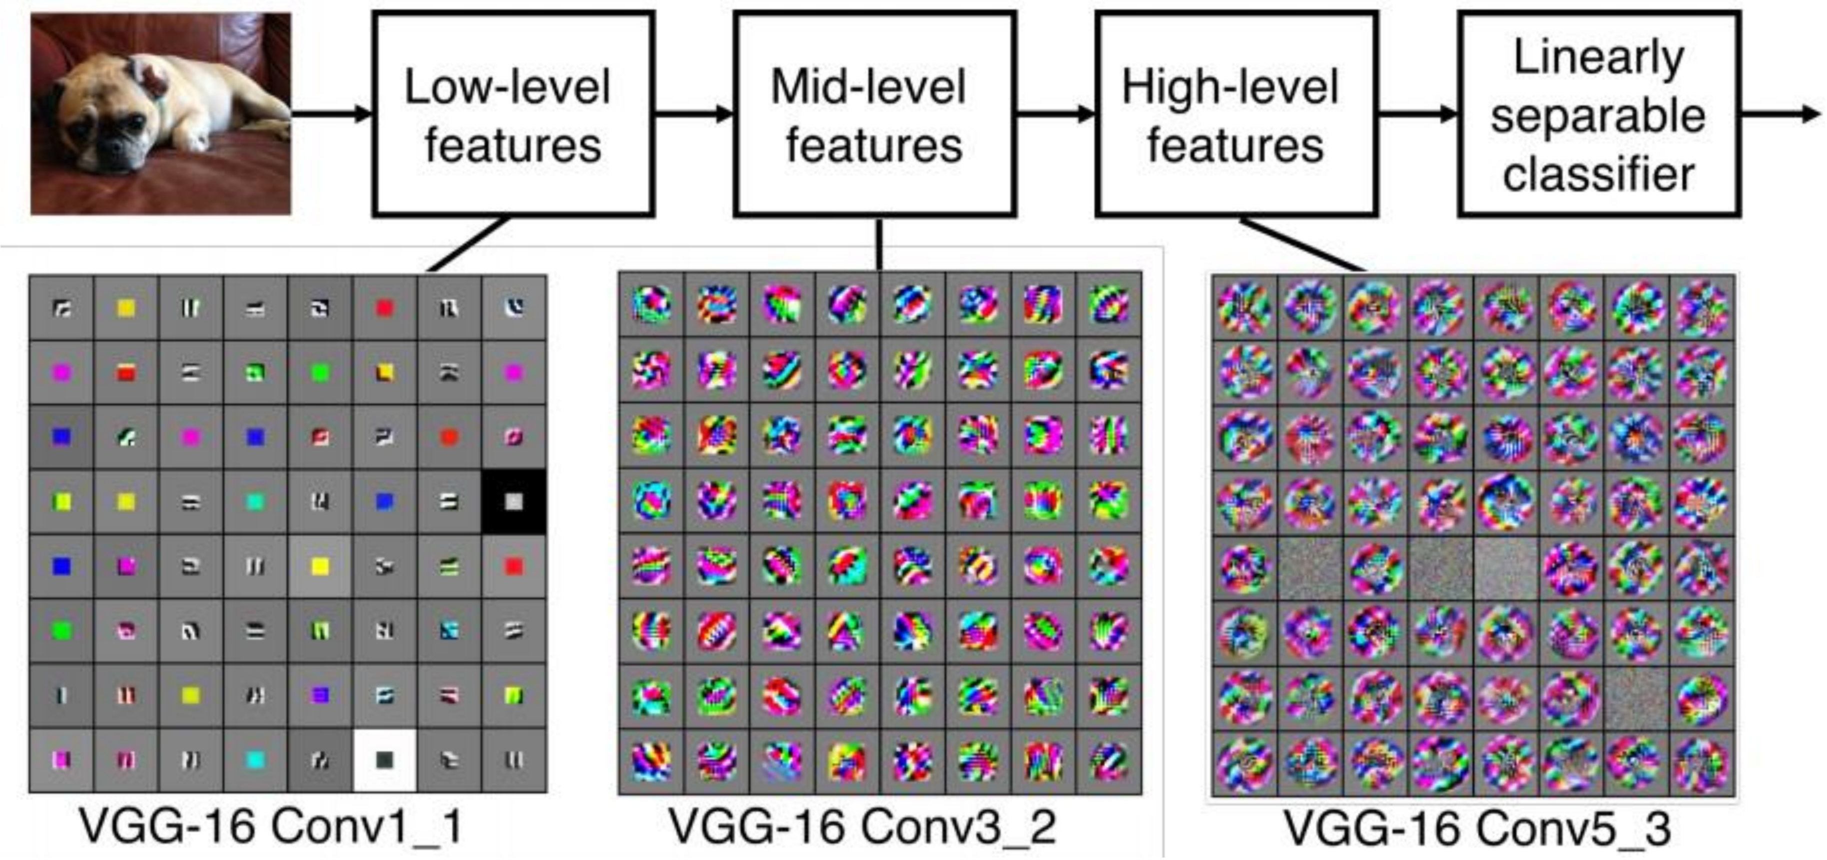
Low-level features
Mid-level features
High-level features
Linearly separable classifier
VGG-16 Conv1_1
VGG-16 Conv3_2
VGG-16 Conv5_3

其它卷积种类

空洞卷积

- 如何增加输出单元的感受野
  - 增加卷积核的大小
  - 增加层数来实现
  - 在卷积之前进行汇聚操作

- 空洞卷积
  - 通过给卷积核插入“空洞”来变相地增加其大小。

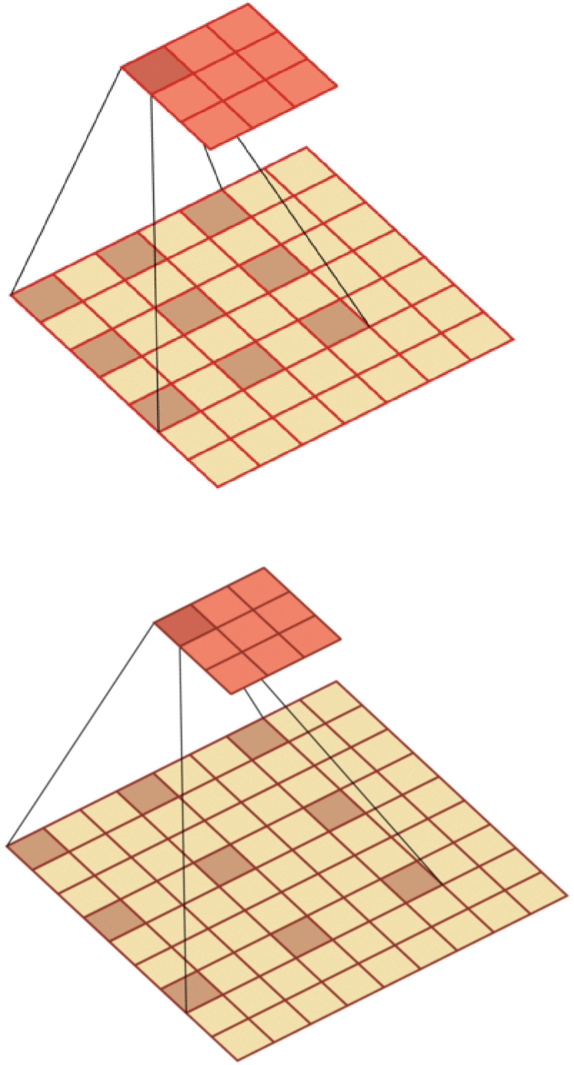

转置卷积/微步卷积

- 低维特征映射到高维特征

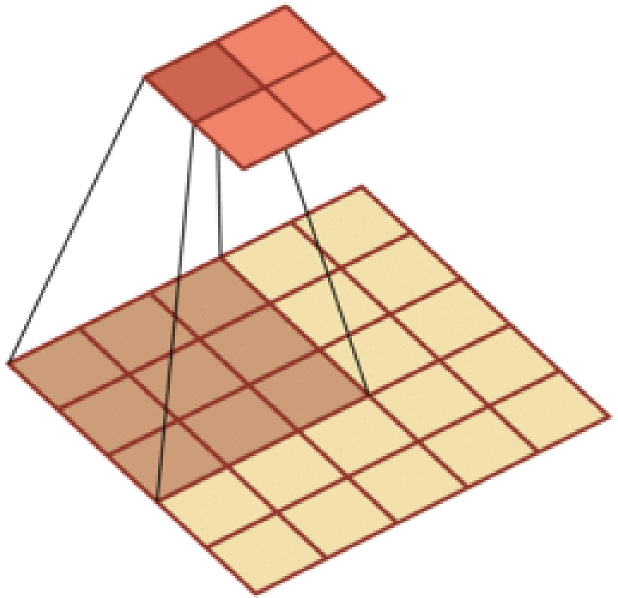

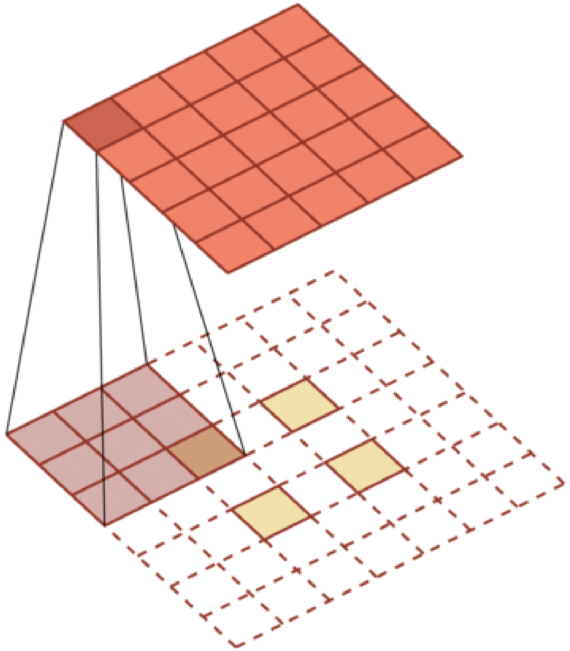

典型的卷积网络

LeNet-5

- LeNet-5 是一个非常成功的神经网络模型。
  - 基于 LeNet-5 的手写数字识别系统在 90 年代被美国很多银行使用，用来识别支票上面的手写数字。
  - LeNet-5 共有 7 层。

需要多少个卷积核?

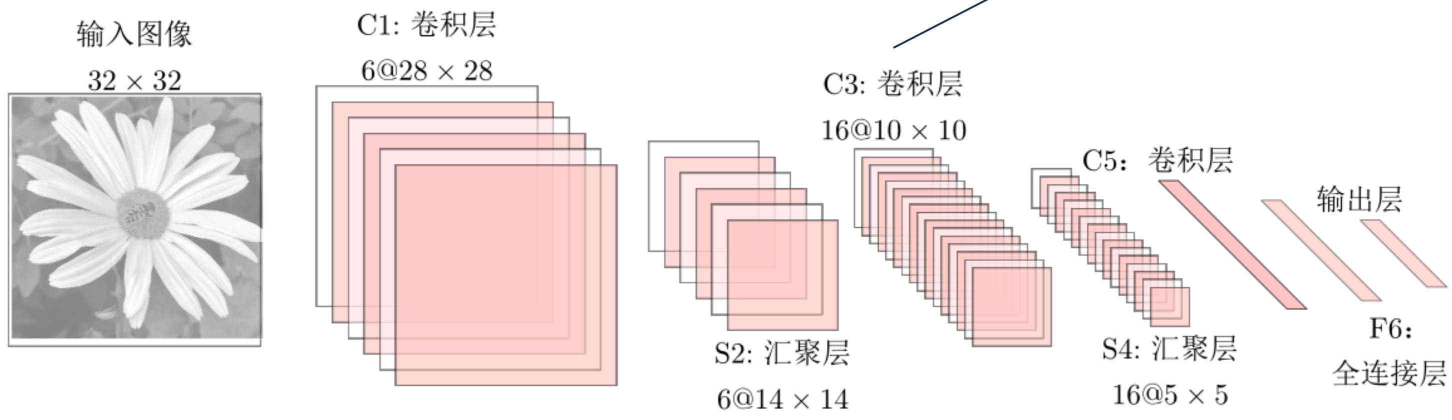

Large Scale Visual Recognition Challenge

2012 Teams	%error
Supervision (Toronto)	15.3
ISI (Tokyo)	26.1
VGG (Oxford)	26.9
XRCE/INRIA	27.0
UvA (Amsterdam)	29.6
INRIA/LEAR	33.4

2013 Teams	%error
Clarifai (NYU spinoff)	11.7
NUS (singapore)	12.9
Zeiler-Fergus (NYU)	13.5
A. Howard	13.5
OverFeat (NYU)	14.1
UvA (Amsterdam)	14.2
Adobe	15.2
VGG (Oxford)	15.2
VGG (Oxford)	23.0

2014 Teams	%error
GoogLeNet	6.6
VGG (Oxford)	7.3
MSRA	8.0
A. Howard	8.1
DeeperVision	9.5
NUS-BST	9.7
TTIC-ECP	10.2
XYZ	11.2
UvA	12.1

AlexNet

- 2012 ILSVRC winner
  - （top 5 error of 16% compared to runner-up with 26% error）
  - 第一个现代深度卷积网络模型
    - 首次使用了很多现代深度卷积网络的一些技术方法
      - 使用GPU进行并行训练，采用了ReLU作为非线性激活函数，使用Dropout防止过拟合，使用数据增强
  - 5个卷积层、3个汇聚层和3个全连接层

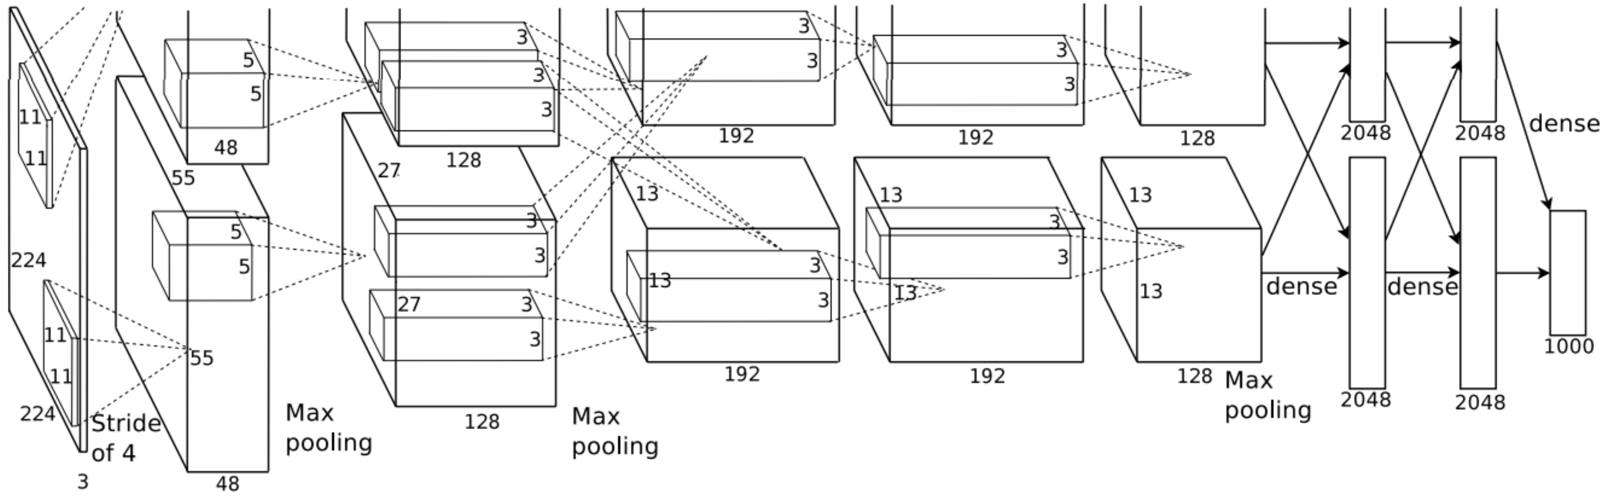

CNN 可视化：滤波器

- AlexNet中的滤波器（96 filters [11x11x3]）

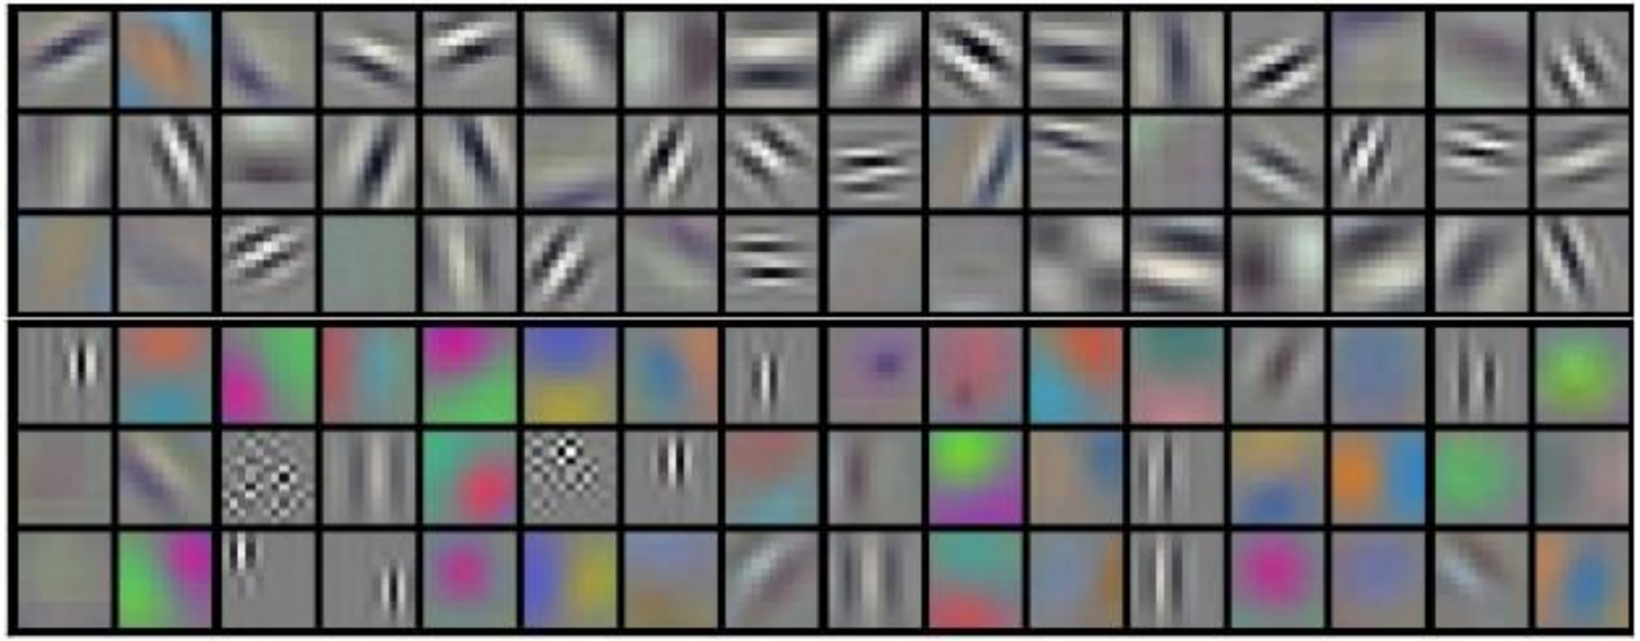

Inception网络

- 2014 ILSVRC winner （22层）
  - 参数：GoogLeNet：4M VS AlexNet：60M
  - 错误率：6.7%
  - Inception网络是由有多个inception模块和少量的汇聚层堆叠而成。

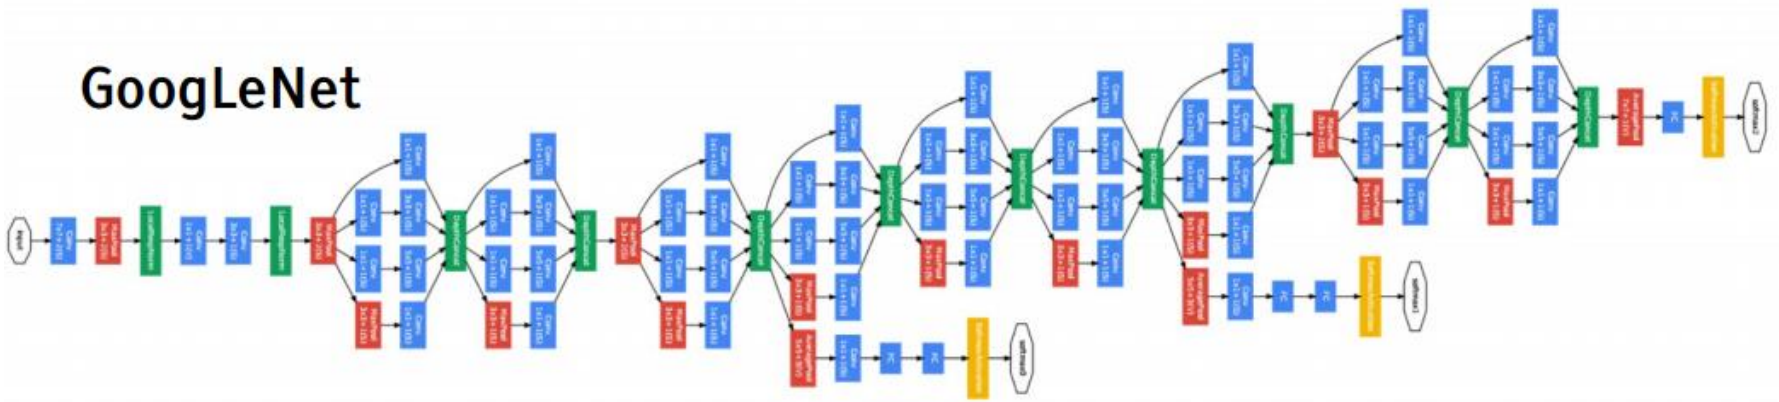

Inception模块 v1

- 在卷积网络中，如何设置卷积层的卷积核大小是一个十分关键的问题。
  - 在Inception网络中，一个卷积层包含多个不同大小的卷积操作，称为Inception模块。
  - Inception模块同时使用1×1、3×3、5×5等不同大小的卷积核，并将得到的特征映射在深度上拼接（堆叠）起来作为输出特征映射。

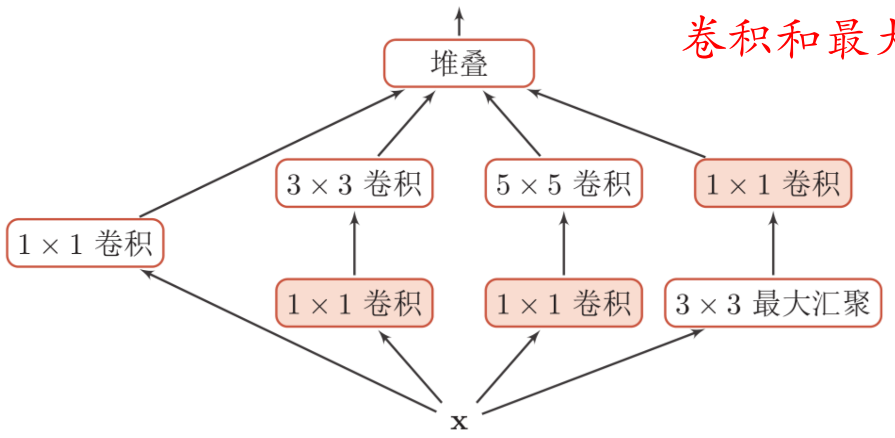

卷积和最大汇聚都是等宽的。

Inception模块 v3

- 用多层的小卷积核来替换大的卷积核，以减少计算量和参数量。
  - 用两层3×3的卷积来替换v1中的5×5的卷积
  - 用连续的n×1和1×n来替换n×n的卷积

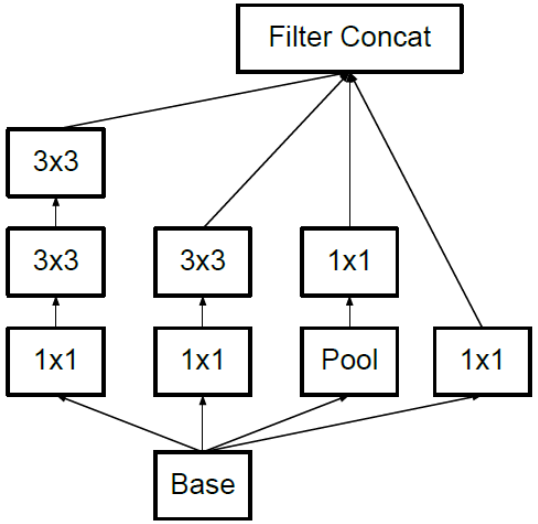

Figure 5. Inception modules where each 5 × 5 convolution is replaced by two 3 × 3 convolution, as suggested by principle 3 of Section 2.

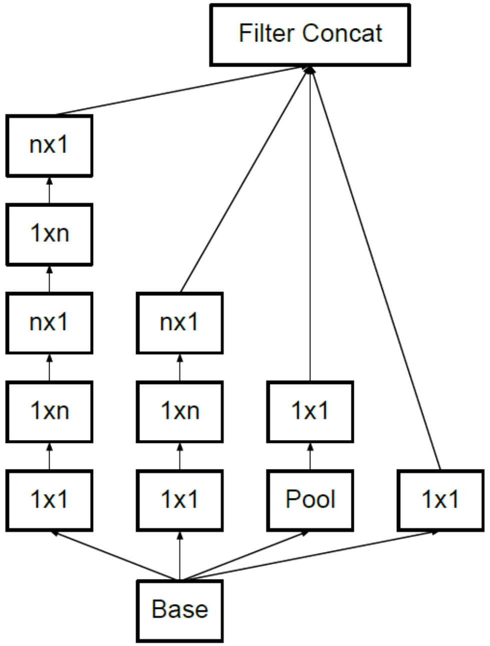

Figure 6. Inception modules after the factorization of the $n \times n$ convolutions. In our proposed architecture, we chose $n = 7$ for the 17×17 grid. (The filter sizes are picked using principle 3)

残差网络（Residual Network，ResNet）

- 2015 ILSVRC winner （152层）
  - 错误率：3.57%

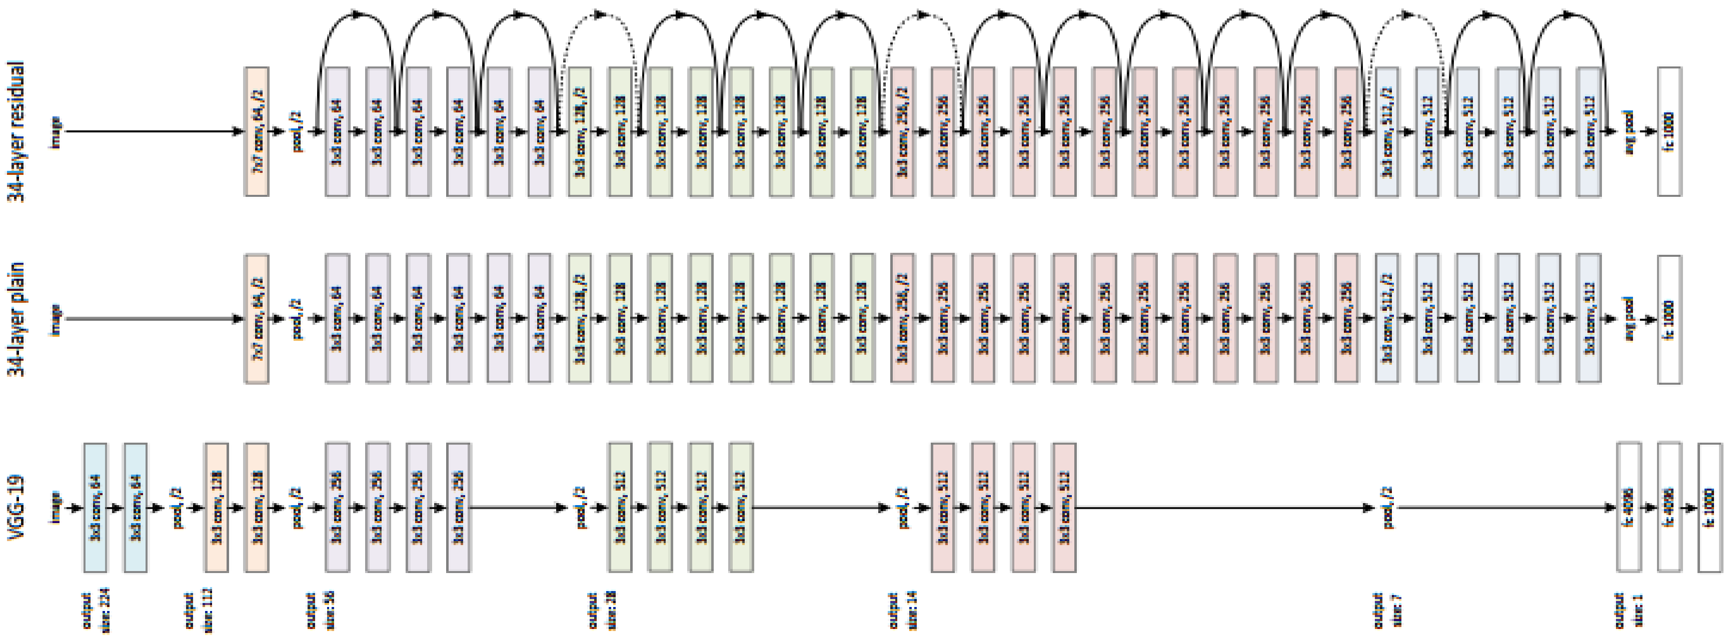

残差网络

- 残差网络是通过给非线性的卷积层增加直连边（shortcut connection）的方式来提高信息的传播效率。
  - 假设在一个深度网络中，我们期望一个非线性单元（可以为一层或多层的卷积层）f(x,θ)去逼近一个目标函数为h(x)。
  - 将目标函数拆分成两部分：恒等函数和残差函数

$$h(\mathbf{x}) = \underbrace{\mathbf{x}}_{\text{恒等函数}} + \underbrace{\left(h(\mathbf{x}) - \mathbf{x}\right)}_{\text{残差函数}}$$

$$\rightarrow f(\mathbf{x}, \theta)$$

残差单元

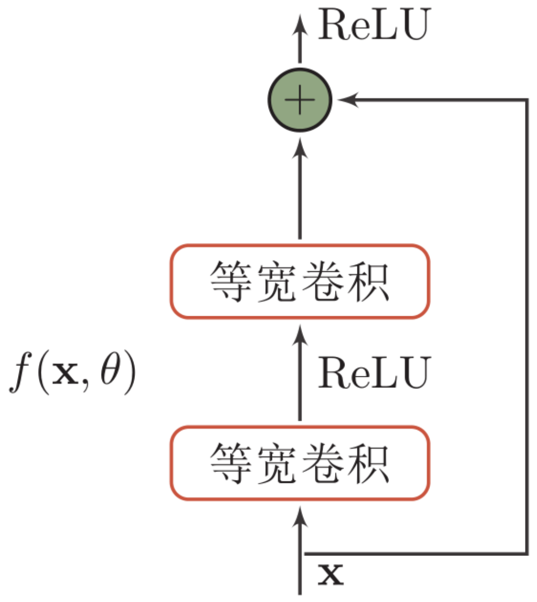
ReLU
等宽卷积
$f(\mathbf{x}, \theta)$
ReLU
等宽卷积
$\mathbf{x}$

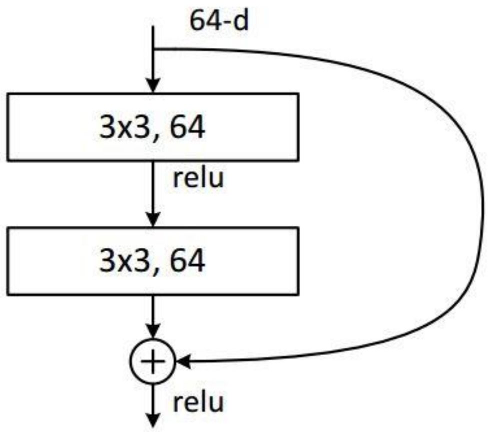
64-d
3x3, 64
relu
3x3, 64
relu

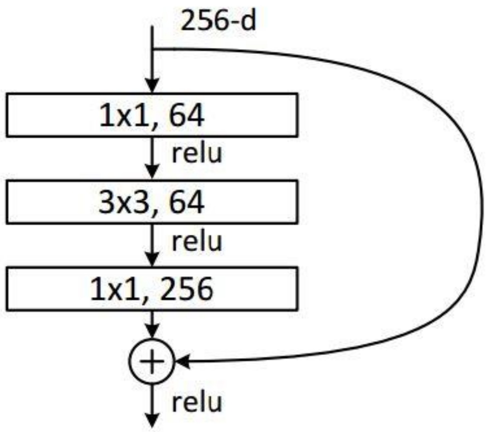
256-d
1x1, 64
relu
3x3, 64
relu
1x1, 256
relu

Ngram特征与卷积

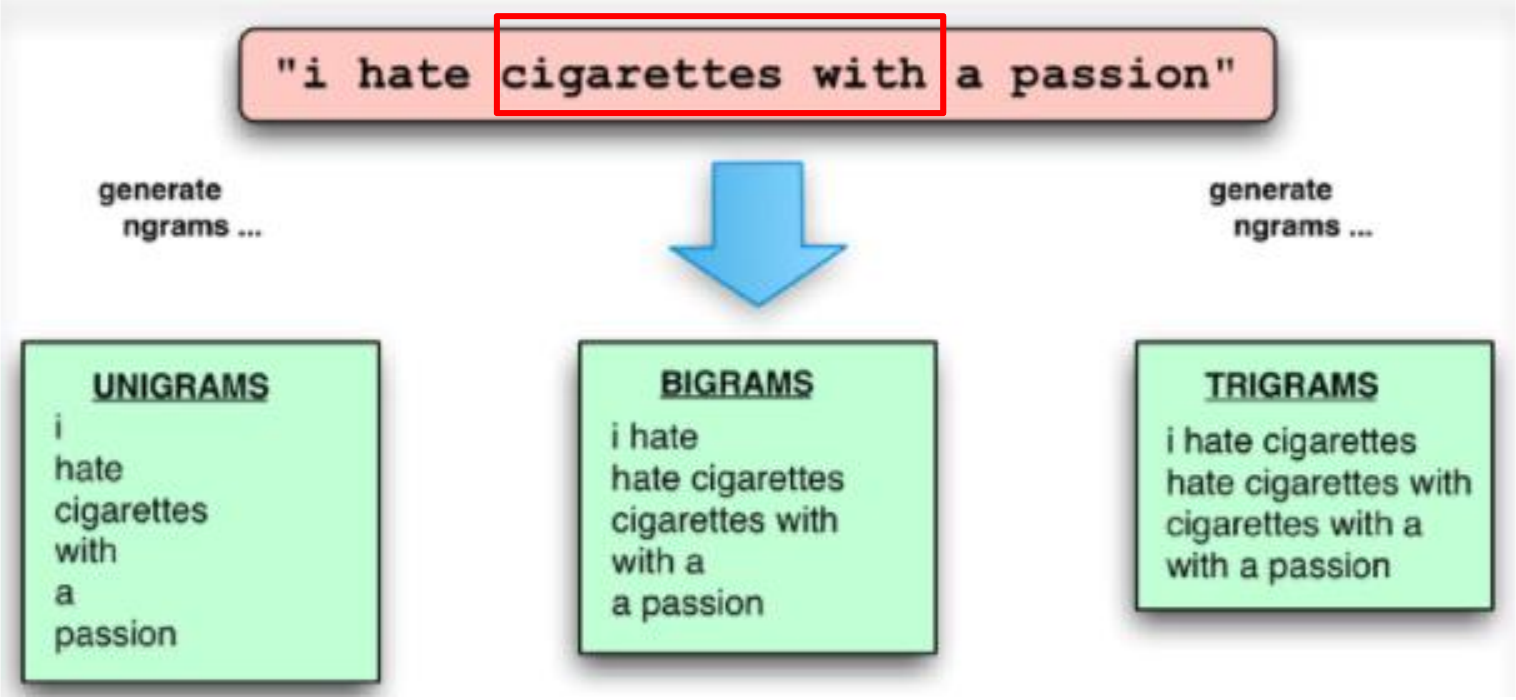

如何用卷积操作来实现?

文本序列的卷积

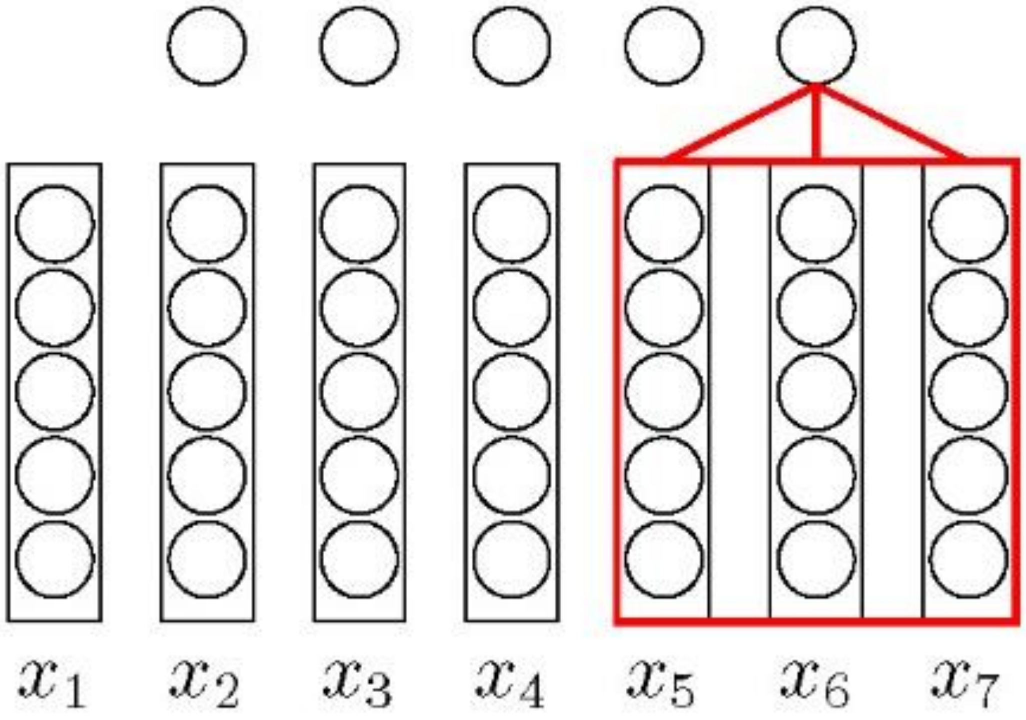

基于卷积模型的句子表示

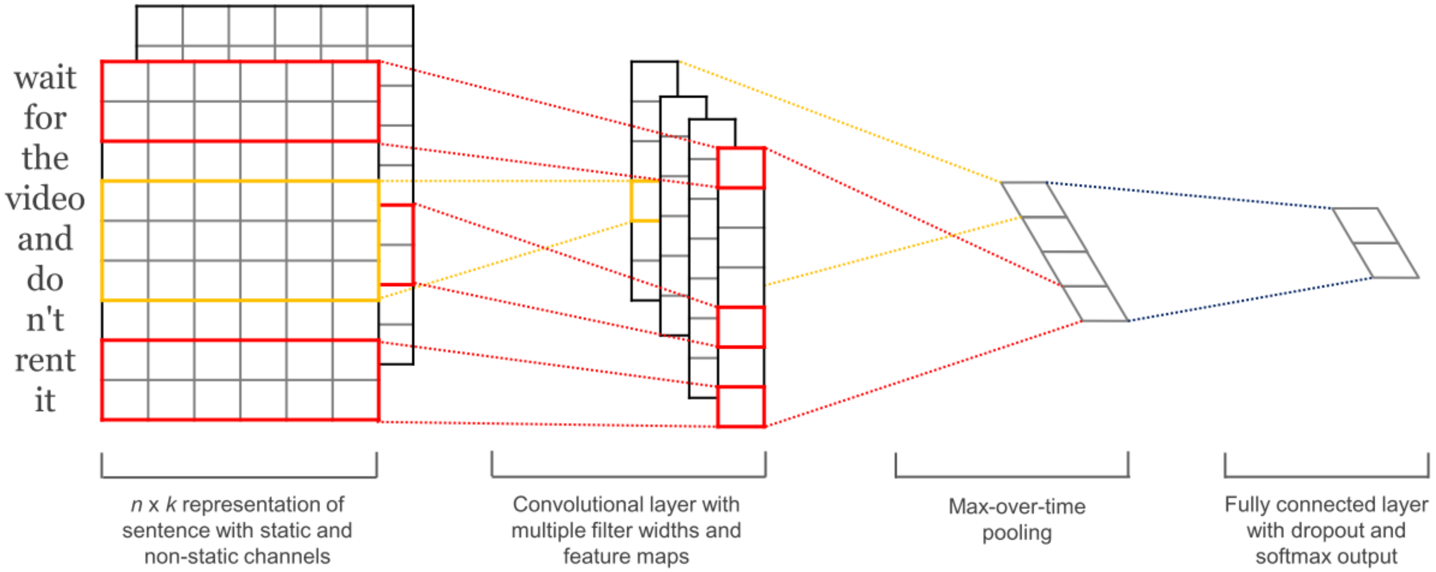

Y. Kim. “Convolutional neural networks for sentence classification”. In: *arXiv preprint arXiv:1408.5882* (2014).

文本序列的卷积模型

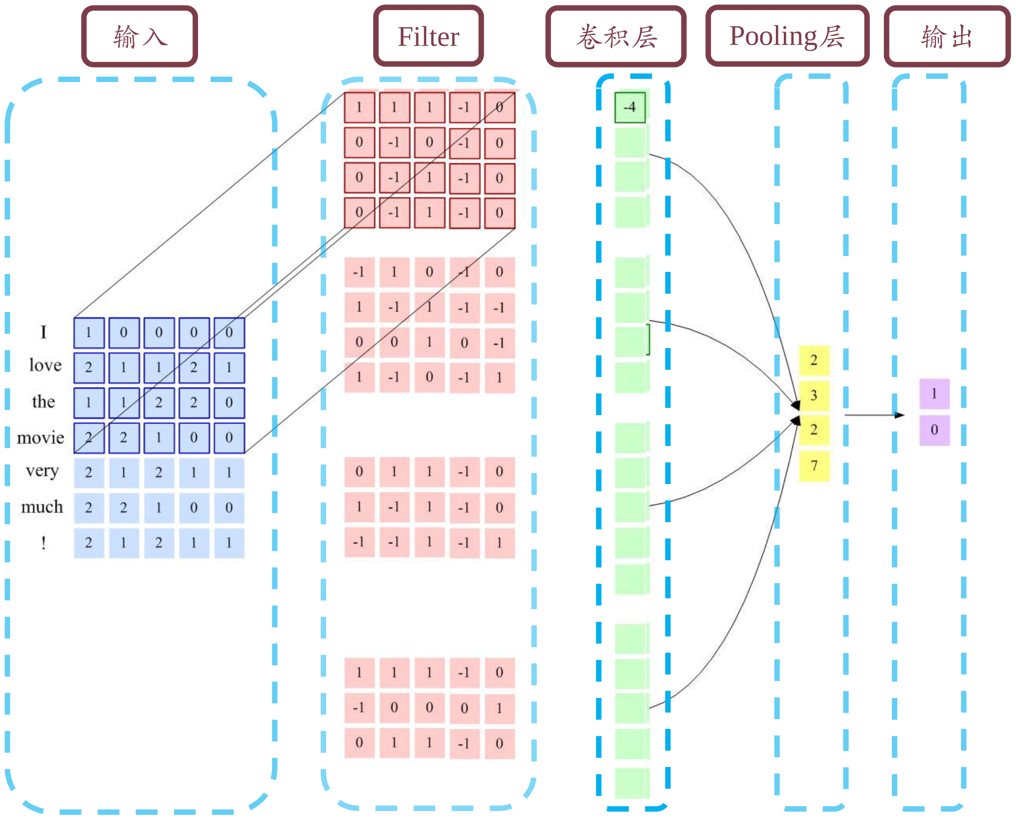

卷积的应用

AlphaGo

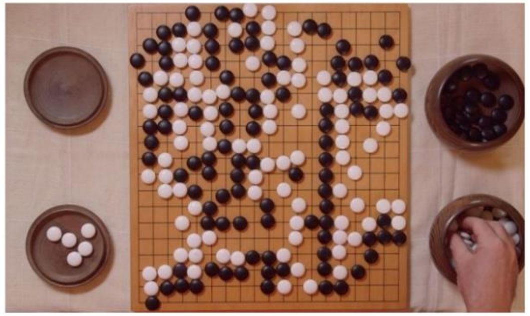

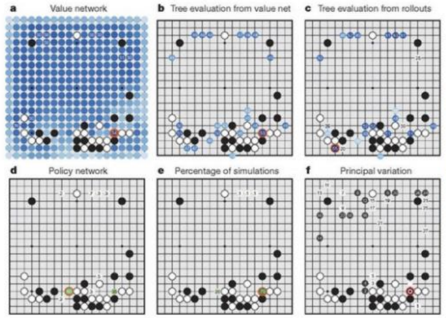

The input to the policy network is a 19 × 19 × 48 image stack consisting of 48 feature planes. The first hidden layer zero pads the input into a 23 × 23 image, then convolves *k* filters of kernel size 5 × 5 with stride 1 with the input image and applies a rectifier nonlinearity. Each of the subsequent hidden layers 2 to 12 zero pads the respective previous hidden layer into a 21 × 21 image, then convolves *k* filters of kernel size 3 × 3 with stride 1, again followed by a rectifier nonlinearity. The final layer convolves 1 filter of kernel size 1 × 1 with stride 1, with a different bias for each position, and applies a softmax function. The match version of AlphaGo used *k* = 192 filters; Fig. 2b and Extended Data Table 3 additionally show the results of training with *k* = 128, 256 and 384 filters.

policy network:
[19x19x48] Input
CONV1: 192 5x5 filters , stride 1, pad 2 => [19x19x192]
CONV2..12: 192 3x3 filters, stride 1, pad 1 => [19x19x192]
CONV: 1 1x1 filter, stride 1, pad 0 => [19x19] *(probability map of promising moves)*

分布式系统：1202 个CPU 和176 块GPU
单机版：48 个CPU 和8 块GPU
走子速度：3 毫秒-2 微秒

目标检测（Object Detection）

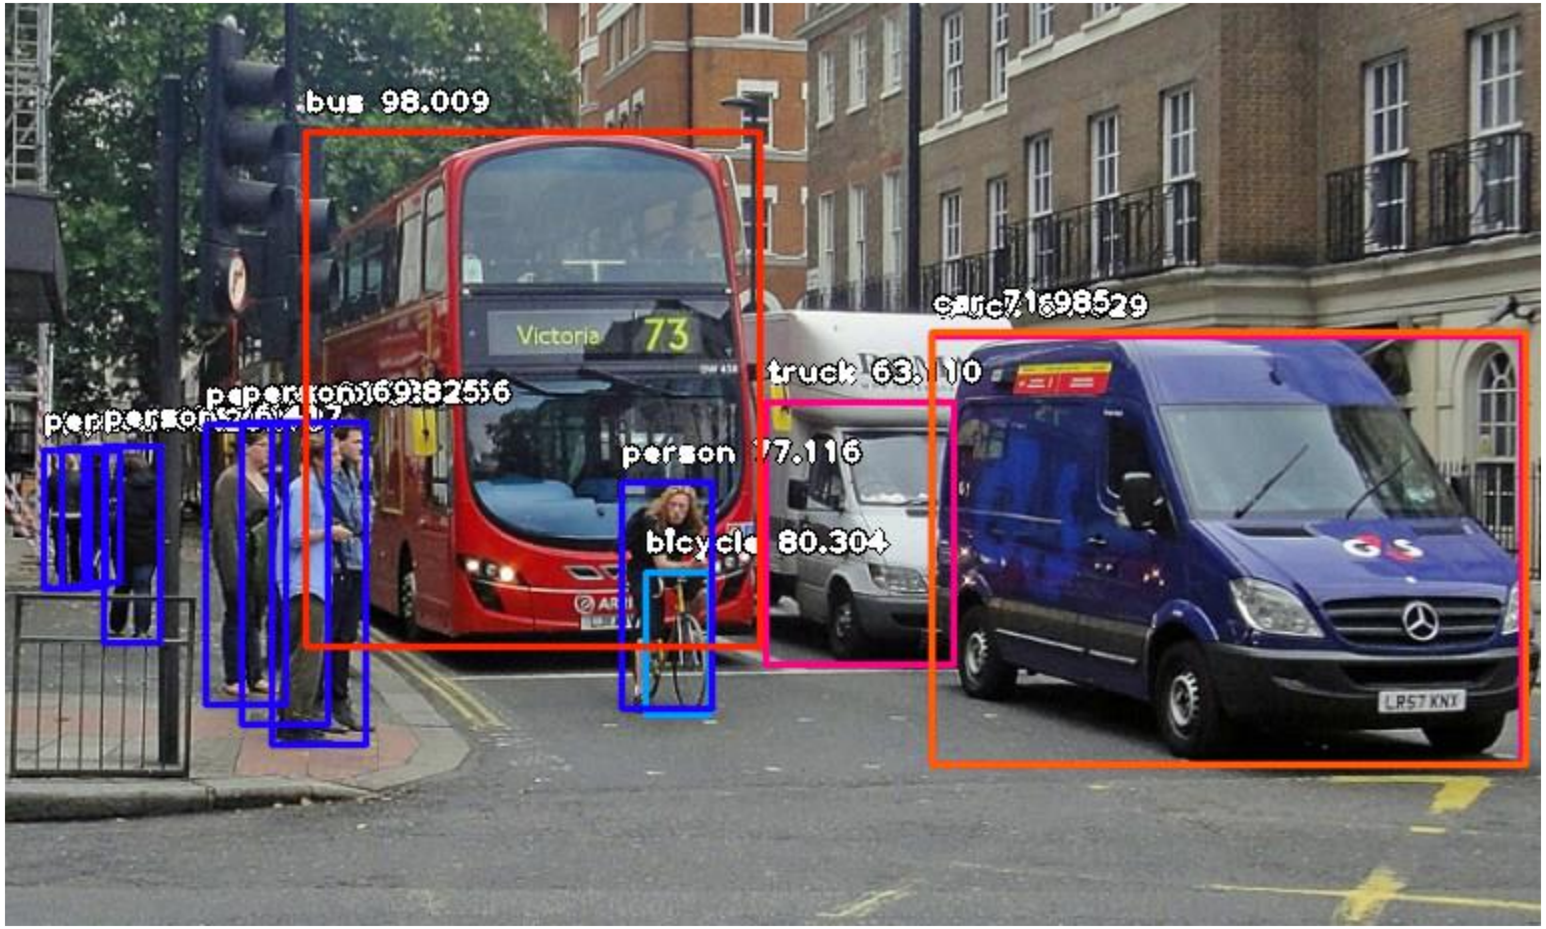

Mask RCNN

Figure 4. More results of **Mask R-CNN** on COCO test images, using ResNet-101-FPN and running at 5 fps, with 35.7 mask AP (Table 1).

OCR


THE WORLD FAMOUS
BRIXHAM
FISH MARKET
BARBER
THE
ROYAL
SCOTSMAN
WESTON
BREWING
1842
COMPANY
THIS WAY
HONOR ★ SERVICE ★ INTEGRITY
AMERICAN
BUILT
ARMS COMPANY
BMW
CLUB
CHARITY RUN
MIZEN HEAD
MALIN HEAD
HOTEL
GREEN
NANTUCKET

课后练习

- 知识点
  - 卷积的本质
  - 卷积网络的结构
  - 残差网络
- 思考题
  - CNN的局部性假设合理吗？如何改进?
- 编程练习
  - https://github.com/nndl/exercise/
  - chap5_CNN
  - 图像分类